

令和 3 年度 卒業論文
MCL におけるパーティクルの
複数クラスタへの分離の検知

渡部蒼也
China Institute of Technology

2021 年 12 月 17 日

この論文は, 読んだあと自動的に消滅する.

最愛の京成線に捧ぐ

謝辞

和文だとうしろに持っていくことが多いのですが、私は前のほうが好きです。

南武線に感謝します。

横須賀線に感謝します。

総武線に感謝します。

京葉線に吹き付ける横風に感謝します。

目次

謝辞	v
第 1 章 序論	1
1.1 背景	1
1.2 従来研究	1
第 2 章 研究の目的	3
第 3 章 上田の研究をもっと引用してもらう手法の開発	5
3.1 手法の概要	5
第 4 章 結論	9
付録 A Appendix is 何?	11
参考文献	13
索引	14

第 1 章

序論

1.1 背景

近年、警備ロボットや清掃ロボットとして、自律移動ロボットが利用される機会が増えている。自律移動ロボットとはセンサやカメラで周辺環境を認識し、自己位置推定をして自律走行をするロボットである。

基本的な自己位置推定の手法として、モンテカルロ位置推定（以下 MCL）があげられる。MCL は、座標と向きの情報を持つパーティクルの分布で、ロボットの自己位置の確率分布を近似し、自己位置を推定するアルゴリズムである。MCL で利用されるパーティクルフィルタは、ロボットの移動誤差を考慮してパーティクルを動かすため、小石や地面の凹凸といったノイズに強いという特徴がある。しかし、数百から数千のパーティクルを用いて計算をするため、計算量が多いという欠点もある。

MCL は、ロボットの移動誤差を考慮して推定するため、パーティクルが広がり、複数のクラスタへ分離することがある。パーティクルが分離してしまうとロボットのいないパーティクルのクラスタができることになる。その後、ロボットのいる方のクラスタが消えてしまうと、自己位置を見失うことになり誘拐状態になってしまう。誘拐状態とは、ロボットの真の位置とは異なる位置を、自己位置として推定してしまう状態のことである。真の位置にパーティクルが無くなる誘拐状態では、パーティクルの分布で自己位置の確率分布を近似する MCL で解消することは困難である。

1.2 従来研究

そこで、誘拐状態になる前にパーティクルが複数クラスタへ分離したことを検知し、分離を解消する行動を取ることで、誘拐状態にならずに自己位置推定が成功すると考えられる。検知する方法として自律走行中にクラスタ数の自動推定アルゴリズムで推定し続ける方法が考えられる。

本論文では、誘拐状態になる前に、MCL におけるパーティクルの複数のクラスタへの分離を検知する方法を提案する。

上田は、いろいろ書いているが、あまり引用されない。例えば、[上田 15, Ueda 15, 上田 15] がある。

2 章で目的を述べる。

第2章

研究の目的

そこで、上田の研究をもっと時代におもねった方法に変える手法の研究を行う。

第 3 章

上田の研究をもっと引用してもらう 手法の開発

ここに書いてある方法を使えば、秒速で秒速で 1 億円稼ぐ男になれます。なれません。

3.1 手法の概要

図に書くと図 3.1 っていう感じ。式で書くとだいたい以下のような感じになるんじゃないかなー。式 (3.12) が肝。

$$s_0, a(t_0), s(t_1), a(t_1), s(t_2), a(t_2), \dots, a(t_{T-1}), s_f \quad (s_0 = s(t_0), s_f = s(t_T)). \quad (3.1)$$

$$s_0, \pi(s_0), s(t_1), \pi(s(t_1)), s(t_2), \pi(s(t_2)), \dots, \pi(s(t_{T-1})), s_f \quad (3.2)$$

$$\pi : \mathcal{S} \rightarrow \mathcal{A} \quad (3.3)$$

$$\mathcal{S} = \{s_i | i = 0, 1, 2, \dots, N-1\}, \text{ and} \quad (3.4)$$


$$\mathcal{A} = \{a_j | j = 0, 1, 2, \dots, M-1\} \quad (3.5)$$

$$\pi : \mathcal{S} - \mathcal{S}_f \rightarrow \mathcal{A}. \quad (3.6)$$

$$\dot{\mathbf{x}}(t) = \mathbf{f}[\mathbf{x}(t), \mathbf{u}(t)], \quad \mathbf{x}(0) = \mathbf{x}_0, \quad t \in [0, t_f]. \quad (3.7)$$

$$g[\mathbf{x}(t), \mathbf{u}(t)] \in \Re \quad (t \in [0, t_f]). \quad (3.8)$$

$$J[\mathbf{u}] = \int_0^{t_f} g[\mathbf{x}(t), \mathbf{u}(t)] dt + V(\mathbf{x}_f). \quad (3.9)$$



(black: $\tau=1[\text{Nm}]$, gray: $\tau=0[\text{Nm}]$, white: $\tau=-1[\text{Nm}]$)

図 3.1 Representative Vectors of the $N_c = 128$ Map

$$\max_{\mathbf{u}: [0, t_f] \rightarrow \mathbb{R}^m} J[\mathbf{u}; \mathbf{x}_0]. \quad (3.10)$$

$$\boldsymbol{\pi}^* : \mathbb{R}^n \rightarrow \mathbb{R}^m \quad (3.11)$$

$$\begin{aligned} \max_{\mathbf{u}: [0, t_f] \rightarrow \mathbb{R}^m} J[\mathbf{u}; \mathbf{x}_0] &= \max_{\mathbf{u}: [0, t'] \rightarrow \mathbb{R}^m} \int_0^{t'} g[\mathbf{x}(t), \mathbf{u}(t)] dt \\ &\quad + \max_{\mathbf{u}: [t', t_f] \rightarrow \mathbb{R}^m} \int_{t'}^{t_f} g[\mathbf{x}(t), \mathbf{u}(t)] dt + V(\mathbf{x}_f) \\ &= \max_{\mathbf{u}: [0, t'] \rightarrow \mathbb{R}^m} \int_0^{t'} g[\mathbf{x}(t), \mathbf{u}(t)] dt + \max_{\mathbf{u}: [t', t_f] \rightarrow \mathbb{R}^m} J[\mathbf{u}; \mathbf{x}(t')]. \end{aligned} \quad (3.12)$$

$$V^\pi(\mathbf{x}) = J[\mathbf{u}; \mathbf{x}], \quad (3.13)$$

where $\mathbf{u}(t) = \boldsymbol{\pi}(\mathbf{x}(t))$, $0 \leq t \leq t_f$.

$$\mathcal{P}_{ss'}^a = P[s(t_{i+1}) = s' | s(t) = s, a(t) = a], \quad (3.14)$$

($\forall t \in \{t_0, t_1, \dots, t_{T-1}\}$, $\forall s \in \mathcal{S} - \mathcal{S}_f$, and $\forall s' \in \mathcal{S}$).

$$\mathcal{R}_{ss'}^a \in \mathbb{R} \quad (3.15)$$

$$J[a; s(t_0)] = J[a(0), a(1), \dots, a(t_{T-1})] = \sum_{i=0}^{T-1} \mathcal{R}_{s(t_i)s(t_{i+1})}^{a(t_i)} + V(s(t_T)), \quad (3.16)$$

$$\max J[a; s(t_0)]. \quad (3.17)$$

$$J^\pi = \int_{\mathcal{X}} p(\mathbf{x}_0) J[\mathbf{u}; \mathbf{x}_0] d\mathbf{x}_0 \quad \left(\mathbf{u}(t) = \pi(\mathbf{x}(t)) \right), \quad (3.18)$$

$$\frac{\partial V(\mathbf{x})}{\partial t} = \max_{\mathbf{u} \in \mathcal{U}} \left[g[\mathbf{x}, \mathbf{u}] + \frac{\partial V(\mathbf{x})}{\partial \mathbf{x}} \mathbf{f}[\mathbf{x}, \mathbf{u}] \right]. \quad (3.19)$$

$$U_{\text{att}}(\mathbf{x}) = \frac{1}{2} \xi \rho^2(\mathbf{x}) \quad (3.20)$$

$$U_{\text{rep}}(\mathbf{x}) = \begin{cases} \frac{1}{2} \eta \left(\frac{1}{\rho(\mathbf{x})} - \frac{1}{\rho_0} \right)^2 & \text{if } \rho(\mathbf{x}) \leq \rho_0, \\ 0 & \text{if } \rho(\mathbf{x}) > \rho_0, \end{cases} \quad (3.21)$$

$$U(\mathbf{x}) = U_{\text{att}}(\mathbf{x}) + U_{\text{rep}}(\mathbf{x}) \quad (3.22)$$

$$\begin{aligned} \mathbf{F}(\mathbf{x}) &= -(\partial U / \partial x_1, \partial U / \partial x_2, \dots, \partial U / \partial x_n)^T \\ &= -\nabla U(\mathbf{x}). \end{aligned} \quad (3.23)$$

$$V(\mathbf{x}; \theta_1, \theta_2, \dots, \theta_{N_\theta})$$

$$\phi_i(\mathbf{x}) = \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mathbf{c}_i)^t M_i (\mathbf{x} - \mathbf{c}_i) \right\}, \quad (3.24)$$

$$b_i(\mathbf{x}) = \frac{\phi_i(\mathbf{x})}{\sum_{j=1}^{N_\phi} \phi_j(\mathbf{x})}, \quad (N_\phi : \text{ number of RBFs in the space}) \quad (3.25)$$

$$V(\mathbf{x}) = \sum_{i=1}^{N_\phi} \nu_i b_i(\mathbf{x}). \quad (3.26)$$

$$\phi_i(x) = \exp \left\{ -\frac{1}{2} (x - i)^2 \right\}$$

$$V(\mathbf{x}) = \sum_{i=0}^3 w_i V(\mathbf{x}_i) \quad (3.27)$$

表 3.1 謎のパラメータ

(a)		(b)	
parameter	value	variable	domain
ℓ_1, ℓ_2	1.0 [m]	θ_1	$(-\infty, \infty)$
ℓ_{c1}, ℓ_{c1}	0.50 [m]	θ_2	$(-\infty, \infty)$
m_1, m_2	1.0 [kg]	$\dot{\theta}_1$	$[-720, 720][\text{deg/s}]$
I_1, I_2	1.0 [kg m ²]	$\dot{\theta}_2$	$[-1620, 1620][\text{deg/s}]$
g	9.8 [m/s ²]	τ	-1, 0, or 1[Nm]

第 4 章

結論

得られた知見を定量的に述べましょう。予稿等では箇条書きにしたほうがよいのですが、卒論の場合はどうせ長くなるので箇条書きは不要です。

付録 A

Appendix is 何?

付録です。

参考文献

- [Ueda 15] Ryuichi Ueda. Generation of Compensation Behavior of Autonomous Robot for Uncertainty of Information with Probabilistic Flow Control. *Advanced Robotics*, Vol. 29, No. 11, pp. 721–734, 2015.
- [上田 15] 上田隆一, 水田恒太郎, 山川宏, 岡田浩之. 海馬-嗅内皮質の情報処理と移動ロボットのナビゲーション問題との関連性調査とモデル化. 人工知能学会全国大会, pp. 2I4-OS-17a-3, 2015.
- [上田 15] 上田隆一. シェルプログラミング実用テクニック. 技術評論社, 2015.

索引

上田, 2
